


EDMIT: 交互式运动辅导中增强决策能力的端到端智能框架

Jinhua Du
dujh22@mails.tsinghua.edu.cn
Tsinghua University
Beijing, China

Ruilin Zhang
Kuaishou
Beijing, China

Mufeng Xing
Ziheng Zhou
Banlan Technology
Suzhou, China

Zexun Jiang
School of Data Science and Intelligent Media
Communication University of China
Beijing, China



IIT: Interactive Exercise Coaching with an End-to-End Intelligent framework

Figure 1: EDMIT 框架总体示意图。系统由三层组成：数据增广层（左）、智能体共演层（中）与反馈闭环层（右）。框架通过从真实教练与用户轨迹中提取“种子数据”，构建可执行的决策链，并在交互中形成持续优化的反馈闭环，实现从人类经验到机器决策的动态迁移。

Abstract

一对一辅导行之有效，但现有基于大模型的教学产品在多轮互动与人机共演中仍难以实现个体化决策。我们聚焦三项问题：如何以低成本从稀缺且非结构化的教练经验构建可用数据；如何设计在互动过程中自适应覆盖个体差异的反馈机制；以及基于 AI 的运动辅导是否能达到甚至超越人类教练。为此，我们提出 EDMIT——面向交互式运动辅导的端到端智能体框架：从教练行为轨迹出发构建“种子→增广”的数据管线，提出标准化决策本体与可执行决策链，并以闭环反馈在会话中自适应调节提示粒度、练习难度与纠错策略。我们实现原型并开展双盲受控研究（10 名用户、10 名教练），在不知来源条件下与提示词式基线比较。结果显示，EDMIT 与人类教练的决策一致性更高，显著提升用户满意度与认可度，并达到同类方法的 SOTA 水平，表明智能体驱动的人机共演可有效弥补个性

允许个人或课堂使用本作品全部或部分制作数字或硬拷贝，无需付费，但前提是这些拷贝不得用于盈利或商业目的，且拷贝的首页必须带有本声明及完整引用信息。对于本作品中不属于美国计算机协会（ACM）的部分，其版权必须得到尊重。经署名的摘要使用是允许的。否则，如需复制、重新发布、在服务器上张贴或重新分发列表，需事先获得特定许可并/或支付费用。请向 permissions@acm.org 申请许可。

Conference acronym 'XX, Woodstock, NY

© 2018 Copyright held by the owner/author(s). Publication rights licensed to ACM.

ACM ISBN 978-1-4503-XXXX-X/2018/06

<https://doi.org/XXXXXXX.XXXXXXX>

化运动辅导中的决策缺口，并为未来 AI 教练系统设计提供实证依据与方法学启示。

CCS Concepts

• Human-centered computing → User models.

Keywords

交互式运动辅导, 智能体框架, 个性化决策, 大型语言模型 (LLM), 数据增广, 反馈闭环, 决策链, 双盲实验, 实证研究

ACM Reference Format:

Jinhua Du, Mufeng Xing, Ziheng Zhou, Ruilin Zhang, and Zexun Jiang. 2018. EDMIT: 交互式运动辅导中增强决策能力的端到端智能框架. In *Proceedings of Make sure to enter the correct conference title from your rights confirmation email (Conference acronym 'XX)*. ACM, New York, NY, USA, 6 pages. <https://doi.org/XXXXXXX.XXXXXXX>

1 Introduction

一对一的人类辅导已被证明是一种非常有效的教学形式 [2]。随着人工智能领域的快速发展特别是基于大型语言模型的相关技术成熟，涌现出诸多服务于用户的智能系统，包括教育 [10]、医疗 [6] 和体育科学 [3] 等。自从以 o1[9] 和 deepseek[4]

为代表的深度推理模型出现，智能系统的推理能力显著增强，已经在数学 [1]、代码 [7] 等领域达到人类博士生水平。

尽管取得这些进展，但在用户使用大模型教学产品，过程中仍面临重大挑战：“个性化决策缺失”。造成该问题的原因在于：常见的智能辅助系统主要以 AI 模型作为算法基础，并通过固定的提示词构建智能问答系统 [5, 8]。单一的提示词和模型本身限制了系统决策适配人机交互过程中由人提出的个性化需求，而且其一次性生成的特性使其在涉及多轮交互与连续决策的场景中难以发挥作用，因此固有的方法并不能有效应对复杂的辅助教学场景。

以辅助运动辅导场景为例，虽然人类教练在教学过程中：能够针对不同的用户情况进行个性化决策，但是使用虚拟教练往往无法简单复刻真实教练的能力。既是因为人类教练的经验往往没有形成固定的文本数据方便模型训练，而且相关数据量不足，也难以完全覆盖多样化的场景需要。因此目前仍没有用户体验较好的交互式运动辅助系统。

为弥补这一空白，在运动辅助领域解决“个性化决策缺失”的问题，我们提出了一个端到端的智能体框架 EDMIT，用于交互式运动辅导中增强 AI 系统的决策能力，最大程度模拟学习人类教练进行运动交互指导中的决策行为。具体而言，通过我们以用户为中心的研究，我们试图回答三个问题：

- 研究问题 1: 如何设计一个全自动的自主 AI 系统，从非常有限的非结构化人类教练经验中，用较低的成本完成系统必要的数据工程输入。
- 研究问题 2: 如何设计一个有效的决策增强系统，以支持在交互式运动中自适应地覆盖用户多样化、个性化的运动辅导需求。
- 研究问题 3: 基于 AI 的运动辅助系统是否能够有效模拟人类教练进行指导，是否有超过人类教练的可能？或者说，基于 AI 的运动辅助系统的智能上限在哪里？

基于对真实教练指导用户的行为轨迹建模与数据采集，我们构造了种子训练数据与评测数据集。在种子训练数据上开发了一个数据增广框架，将种子训练数据扩展到任意尺度，以覆盖构造智能 AI 系统的数据需要（研究问题 1）；通过借鉴人类运动学习中的“反馈闭环理念”，我们标准化建模了在辅助运动辅导场景下所有可能的决策节点，并系统化构造出完整的智能决策链，通过智能体驱动整个决策链的具体执行，自适应地为多样化、个性化用户提供运动辅导服务（研究问题 2）。

为评估基于 EDMIT 框架是否能真正帮助用户提升其运动水平，我们首创性地在 AI 运动辅助领域引入“双盲实验”。我们开发了一个采用 EDMIT 的原型系统来为真实用户提供服务，用户事先无法确认服务来源是真实教练还是虚拟教练，并在辅助教学结束后为多个方案进行打分。我们通过对 10 名真实用户和 10 名真实教练进行受控用户研究，比较了 EDMIT 和真实教练的一致性，以及和其他传统方法的性能差异（研究问题 3）。结果表明，EDMIT 框架能提供人类教练水平的决策能力，达到已有方法中的 SOTA 水平，显著增强用户对 AI 辅助运动产品的认可度和满意度。

总之，我们的研究探索了一个交互式运动辅导中增强决策能力的端到端智能框架，以弥合人类教练经验和 AI 系统的智能差距，从而提升用户的运动学习效果。我们的贡献体现在四个方面：1) 一个复杂系统框架，给出了交互式运动辅导中增强决策能力的方法论；2) 一个开源系统，提供框架对应的代码实例和产品，支持后续研究；3) 一项用户研究，评估了我们的 AI 系统设计对用户的有效性；4) 为设计未来 AI 驱动的

交互式运动辅助系统提供了见解，旨在实现个性化辅助运动教学中有效的人机交互。

2 Related Work (LLM 生成)

本节回顾与 EDMIT 框架相关的两类研究：一是关于 **AI 辅助决策 (AI-assisted decision making)** 的理论与方法，二是关于 **AI 驱动交互式运动辅导 (AI-driven interactive coaching)** 的系统与应用。

2.1 AI 辅助决策 (AI-assisted Decision Making)

人工智能在辅助人类决策方面的研究已在多个领域展开，包括医疗诊断、教育辅导与人机协作任务等。随着大型语言模型 (Large Language Models, LLMs) 的快速发展，AI 辅助决策系统逐渐从“静态建议生成”转向“动态交互式推理”[]。这一转变使系统不仅能够提供事实性答案，更能在多轮交互中形成结构化的决策路径。

在教育场景中，智能辅导系统 (Intelligent Tutoring Systems, ITS) 长期以来被用于支持学习者的推理与反思过程[]。近年来的研究尝试引入大模型以增强系统的自适应性与个体化能力[]。例如，DDxTutor 系统提出了一种基于差分诊断 (Differential Diagnosis) 结构化推理的临床教学模式，能够在模拟诊疗过程中为学生提供逐步的推理反馈与纠错指导[]。这些研究为我们构建具备“决策链逻辑”的 AI 教练系统提供了启发：在运动辅导等领域，系统的价值不在于给出最终答案，而在于如何在交互中帮助用户形成正确的思维与决策路径。

此外，AI 辅助决策的研究也强调了人机协作过程中的信任建立与解释透明性[]。EDMIT 的设计正是借鉴了此类研究中的“可解释决策”理念，通过显式建模决策链与反馈闭环，使系统在连续互动中逐步学习并自我修正。

2.2 AI 驱动的交互式运动辅导 (AI-driven Interactive Coaching)

近年来，随着动作识别、语音分析与多模态交互技术的发展，AI 驱动的运动辅导系统成为人机交互研究的活跃方向。早期工作主要聚焦于基于传感器的姿态识别与错误检测[]，例如利用可穿戴设备或摄像头数据识别用户的运动动作并提供即时反馈[]。这些系统在动作精度与姿势纠正方面取得了一定成效，但普遍缺乏决策层面的自适应性，难以针对用户差异提供个性化指导。

随后，一些研究尝试将自然语言交互引入运动辅导系统，使用户能以对话形式获得反馈或建议[]。此类方法提高了交互的可达性 (accessibility)，但其策略生成仍基于规则模板或固定对话流程，在面对动态场景或个体差异时表现受限。

随着 LLM 的推理与生成能力提升，出现了多种 AI 教练原型系统，例如面向健身训练、康复治疗和日常运动指导的开源框架[]。这些系统通常结合姿态估计、语义理解与语言生成模块，实现从感知到反馈的闭环控制。然而，大多数方法仍依赖单轮输入输出机制，缺乏对“教练-学员”双向互动动态的系统性建模。

EDMIT 在此基础上更进一步：它将 AI 教练视为具备自我优化能力的智能体，通过种子数据增广、决策链建模与交互闭环机制，实现了真正意义上的“共演式运动辅导” (co-adaptive interactive coaching)。这种方法不仅改善了反馈质量，也为构建长期、个性化的 AI 辅导系统提供了可复用的设计框架。

总体而言，现有研究在 AI 辅助决策与运动辅导系统两个方向均取得了重要进展，但仍存在数据稀缺、个体适配不足与反

馈机制单一等问题。EDMIT 的创新之处在于，将决策逻辑、数据增广与交互适应统一到一个可演化的智能体框架中，从而实现了人机共演的个性化运动辅导模式，为未来的交互式 AI 系统设计提供了新的理论与实践参考。

3 Framework: EDMIT

为了增强 AI 在交互式运动辅导中的决策能力，我们构建了 EDMIT 框架，其核心思想是通过数据增广—决策建模—反馈闭环优化三个阶段，实现从人类教练经验到智能体行为的端到端迁移。整个过程以“人机共演”（human-AI co-agency）的理念为指导，使 AI 教练能够持续学习、调整并优化自身的决策行为。

3.1 数据增广管线 (Data Augmentation Pipeline)

我们首先从真实教练指导用户的行为轨迹出发，对其进行系统建模与标准化采集。这些轨迹通常包含姿态纠正、鼓励指令、节奏调节等多类型决策信息。

然而，人工采集过程存在三重限制：(1) 单次采集需以小时为单位，人工成本高；(2) 采样分布非均匀，难以覆盖完整场景；(3) 校对依赖人工审核，效率低。

为此，我们提出一种种子驱动的数据增广框架：1. 将少量高质量的行为轨迹数据视为“种子数据 (seed set)”，并通过控制采样策略保证其在决策空间中的代表性；2. 利用大语言模型对这些轨迹进行语义归纳与行为抽取，生成教练决策行为与用户响应行为的双向映射；3. 将提取出的行为以标准化元数据 (metadata) 的形式重构为可执行提示 (prompt templates)，为智能体的决策生成提供基础知识，具体流程详见图2。




Figure 2: 数据增广 workflow.

3.2 智能体构建与自我增广 (Agentic Simulation and Self-Augmentation)

在完成数据归纳后，我们分别构建了两个智能体：• AI 教练智能体 (AI-Coach Agent)，其行为策略来源于教练决策数据；• AI 用户智能体 (AI-User Agent)，其反应模式来源于用户响应数据。

两个智能体以对话和动作反馈的形式进行人机共演式模拟 (co-simulation)。AI 教练在给定情境下生成决策，AI 用户基于

决策生成响应行为；系统再将这组模拟结果与真实轨迹进行对齐，从而生成新的伪轨迹数据。该过程允许在不增加人工成本的情况下，实现潜在“无限轨迹”的生成与学习，并在交互中自我修正。

为了防止增广偏移 (augmentation drift)，我们采用数据自净化机制 (data self-refinement)：将种子集划分为 80% 的原始训练集与 20% 的验证集。智能体在验证集上生成的轨迹若与真实数据不一致，则将差异部分作为负反馈样本，用于优化其行为生成策略。通过多轮自校验，系统能在模拟空间中逐步收敛到与真实教练行为一致的决策模式。

3.3 决策链与反馈闭环 (Decision Chain and Adaptive Feedback Loop)

人类运动学习往往依赖教练与学员之间的双向反馈循环 (feedback loop)，这种理念同样被迁移至 EDMIT 的决策机制设计中。我们将每一次教练与用户的交互视为一个决策链 (decision chain)，由多个决策节点 (decision nodes) 组成，每个节点包含输入状态、决策输出、用户响应与反馈信号。

在每个节点中，AI 教练依据前述增广数据学习的决策函数生成动作决策；系统同步提取真实用户响应与 AI 用户模拟响应，形成两类反馈：• 响应反馈 (Response Feedback)：比较 AI 用户与真实用户在动作、语言、情绪等层面的差异；• 决策反馈 (Decision Feedback)：量化 AI 教练决策与人类教练之间在策略层面的偏差。

系统以这些差异为优化目标，自动调整决策函数参数。当反馈收敛时，系统冻结现有的决策链结构；当误差长期停滞时，系统触发锚点调整机制 (anchor-point adaptation)：基于专家定义的基础锚点 (data anchors)，AI 教练可主动提出增加、删除或重构决策节点，以引入新的反馈信号。这一机制确保系统在长期学习中保持自适应性与决策的多样性，最终形成一个可持续优化的闭环智能体体系，具体流程详见图3。




Figure 3: 决策链.

4 User Study

为验证 EDMIT 框架在交互式运动辅导场景中的有效性与可用性，我们设计并实施了一项包含 **10 名真实教练与 10 名真实用户** 的双盲对照实验。本研究旨在系统评估基于 EDMIT 的 AI 教练在真实与增广场景下的决策一致性、交互体验与信任建立效果。

4.1 研究设计 (Study Design)

参与者. 我们邀请了来自三家健身机构的 10 名具有专业认证的运动教练 (平均工作年限 5.3 年), 以及 10 名具有基础运动习惯的普通用户 (平均每周运动 2–3 次)。所有参与者均签署知情同意书, 并在实验前完成基线问卷调查, 以记录其运动偏好、身体状况及对 AI 辅导系统的既有态度。

任务设置. 实验包含两类典型的运动辅导任务:

- 力量训练 (Strength Training)**: 侧重动作幅度、姿态纠正与节奏控制;
- 姿势矫正 (Posture Adjustment)**: 涉及个体化动作建议与持续性反馈。

每个任务场景均由真实教练先行执行, 以生成标准化的行为轨迹 (ground-truth trace), 并在此基础上生成对应的增广轨迹数据。

4.2 实验条件 (Experimental Conditions)

我们在两种数据条件下分别对系统进行评估:

- 真实轨迹条件 (Real Trace)**: 基于人类教练与用户的真实互动数据;
- 增广轨迹条件 (Augmented Trace)**: 基于 EDMIT 框架生成的模拟数据。

在每种条件下, 设置四个实验组以进行对比:

- Human Coach** (真实教练);
- Vanilla LLM** (裸 LLM, 无额外提示或强化模块);
- Baseline System** (相关工作, 实现基于规则或单回合提示的交互系统);
- EDMIT** (本文提出的框架)。

每位教练与用户均与四个系统分别交互, 交互顺序采用拉丁方设计随机化, 以避免学习与顺序效应。实验全程采用双盲方式, 参与者和评估者均不知晓交互对象 (人类或 AI) 的具体身份。

4.3 评测指标 (Evaluation Metrics)

我们从三个层面评估 EDMIT 的性能:

- 决策一致性 (Decision Consistency)**: 衡量系统生成的动作决策与人类教练决策之间的一致程度。采用基于决策节点的匹配度指标 (F1-score 与语义一致率), 并进行消融分析以比较 EDMIT 各模块 (数据增广、决策链、闭环反馈) 的贡献;
- 主观感知指标 (Perceived Utility & Satisfaction)**: 包括用户满意度 (Likert 7 分量表)、系统信任度 (System Trust Index) 与交互自然度;
- 专家评审指标 (Expert Evaluation)**: 由 5 名独立专业教练对系统输出进行盲评, 从动作合理性、指导准确性与语言清晰度三方面打分。

4.4 实验流程 (Procedure)

每位用户完成两个任务 (力量训练与姿势矫正), 每个任务约 20 分钟。交互完成后, 参与者需填写问卷并接受半结构化访谈, 以收集定性反馈。所有交互过程的语音与文本记录均用于后续一致性计算与行为分析。

此外, 我们设计了两项针对不同目标的子实验:

- 一致性对比实验 (Decision Consistency Test)**:

Table 1: 不同系统在主要指标上的对比结果 (模拟数据)。

System	Decision Consistency (F1)	User Satisfaction (1–7)	Trust Index (0–1)	Expert Rating (1–10)
Human Coach	0.90	6.4	0.91	9.2
Baseline System	0.71	4.8	0.59	6.3
Vanilla LLM	0.62	4.2	0.47	5.5
EDMIT	0.87	6.1	0.83	8.9

- 在真实轨迹条件下, 比较裸 LLM、相关工作与 EDMIT 的决策一致性, 验证其是否能达到甚至超越人类教练水平;
- 在增广轨迹条件下, 比较真实教练、裸 LLM、相关工作与 EDMIT, 分析数据增广对模型泛化能力的影响。

(2) 实用性双盲实验 (Practical Utility Test):

- 用户视角**: 在不知情条件下, 用户分别体验四类系统, 并评价交互体验、信任感与偏好;
- 教练视角**: 让真实教练盲评各系统生成的指导内容, 判断其专业性 with 贴合度。

4.5 数据分析 (Data Analysis)

我们采用混合设计方差分析 (Mixed-design ANOVA) 比较不同系统间的显著差异。事后检验使用 Tukey HSD 校正, 显著性阈值设为 $p < 0.05$ 。对于访谈数据, 我们使用主题分析 (Thematic Analysis) 方法, 对用户与教练的定性反馈进行编码与归纳, 以识别影响信任建立与人机共演体验的关键主题。

5 Results

本节展示 EDMIT 框架在交互式运动辅导任务中的定量与定性结果。我们从决策一致性、用户满意度、系统信任度及专家评审四个维度进行综合评估, 并结合半结构化访谈探讨用户与教练对 AI 教练行为的主观感受。

5.1 定量分析 (Quantitative Analysis)

总体表现. 表 1 总结了 EDMIT、裸 LLM、基线系统以及人类教练在真实与增广轨迹条件下的主要结果。在决策一致性 (Decision Consistency) 方面, EDMIT 平均达到 0.87 的 F1-score, 与人类教练 (0.90) 差距仅 3.3%, 显著高于裸 LLM (0.62) 与基线系统 (0.71)。在主观满意度 (User Satisfaction, 7 分制) 上, 用户对 EDMIT 的平均评分为 6.1, 显著高于基线系统的 4.8 ($p < 0.01$), 与人类教练的 6.4 无显著差异 ($p = 0.21$)。系统信任度 (System Trust Index) 方面, EDMIT 得分为 0.83 (归一化至 $[0, 1]$ 区间), 较裸 LLM 提升 41.6%。

消融分析 (Ablation Study). 为验证框架各组成模块的贡献, 我们分别移除“数据增广模块”、“决策链模块”与“闭环反馈模块”进行消融实验。结果显示, 去除决策链模块后系统 F1-score 从 0.87 降至 0.79, 满意度降幅约 14%; 若同时移除反馈闭环, F1-score 进一步降至 0.72。这表明 EDMIT 的高决策一致性主要得益于其可解释的决策链结构与基于反馈的持续优化。

统计显著性. 混合设计方差分析 (Mixed-design ANOVA) 结果表明, 系统类型对决策一致性有显著主效应 ($F(3, 27) = 18.42$, $p < 0.001$)。事后 Tukey HSD 检验显示, EDMIT 与人类教练间差异不显著 ($p = 0.21$), 但显著优于裸 LLM ($p < 0.001$) 与基线系统 ($p = 0.004$)。在用户满意度方面亦观察到类似趋势 ($F(3, 27) = 11.63$, $p < 0.001$)。




Figure 4: 不同系统在决策一致性、满意度与信任度上的表现对比（模拟数据）。误差条表示标准差。

专家评审. 五位独立专业教练对系统输出的指导准确性、动作合理性与语言清晰度进行盲评（满分 10 分）。EDMIT 的平均得分为 8.9，与人类教练 (9.2) 接近，显著高于裸 LLM (5.5) 与基线系统 (6.3)，说明该框架在决策合理性与可解释性上具有较强的专业一致性。

5.2 定性访谈 (Qualitative Insights)

为进一步理解用户对 AI 教练行为的主观体验，我们从 20 份访谈记录中提取了 128 条有效反馈，并采用主题分析法 (Thematic Analysis) 归纳出三类主要主题：信任与真实感、自适应性体验、人机共演感知。

主题一：信任与真实感 (Trust and Realism). 多数用户认为 EDMIT 的反馈“自然且富有同理心”，能够在语气、节奏和反馈层级上接近真实教练。一位用户表示：“我几乎忘了它是 AI，感觉真的有人在关注我的状态。”与此相对，裸 LLM 的反馈常被描述为“单调”“机械”，难以建立信任。

主题二：自适应性体验 (Adaptive Guidance). 用户普遍指出 EDMIT 在节奏调控与错误纠正方面更具灵活性。系统能根据用户反馈自动调整提示粒度，例如“在我动作对了之后，它会自动减少提示频率”。这一特性提高了用户的自我掌控感 (sense of agency)。

主题三：人机共演感知 (Perceived Co-agency). 多位受访者表示 EDMIT “不像是在被指令”，而更像“在与教练合作完成目标”。这种“共演式交互”增强了动机与沉浸感，尤其在姿势矫正任务中表现明显。教练受访者也指出，AI 的决策链呈现出“逻辑清晰、符合训练思维”的特征，有助于未来用于教练培训。

综合来看，EDMIT 框架在定量指标上显著接近人类教练水平，并在定性反馈中展现出更高的互动自然度与信任建立能力。这些结果表明，EDMIT 不仅在决策层面实现了类人一致性，还在交互层面形成了可持续的人机共演体验，为未来 AI 驱动的个性化运动辅导系统提供了方法学与实践启示。

6 Discussion

6.1 框架与主要发现回顾 (Summary of Findings)

EDMIT 的框架将数据增广、智能体共演与反馈闭环有机结合，构成了一个从人类经验到机器决策的动态迁移路径。该框架不仅能够以低成本扩展有限的教练数据资源，还能在交互过程中持续优化决策能力，最终实现与人类教练水平相当的个性化运动辅导体验。

通过结合真实与增广场景的双盲评测，我们在多维指标上系统验证了 EDMIT 框架的有效性。结果表明，EDMIT 在决策一致性、用户满意度与教练认可度方面均显著优于裸 LLM 与现有基线系统，其表现已接近人类教练水平。这表明基于智能体的决策链机制与反馈闭环可以有效提升交互式运动辅导中的个性化决策质量。

6.2 对 AI 教练系统设计的启示 (Design Implications)

我们的研究揭示了三点对 AI 教练系统设计的启示：

1. 以决策链为核心的可解释性结构. 传统的交互式 AI 教练往往依赖隐式的提示模板或端到端生成，难以追踪系统的决策依据。EDMIT 的决策链设计为系统提供了显式的推理路径，使每一步决策都具备可解释性 (interpretability) 与可干预性 (intervenability)。这一设计模式为未来的智能辅导系统提供了一个通用的设计范式，可用于诊断、调试与伦理审查。

2. 数据增广驱动的可扩展学习. 在 AI 教练场景中，真实标注数据极为稀缺。我们的结果表明，基于行为轨迹的“种子-增广”机制可在不增加采集成本的前提下有效提升模型的泛化能力。这一结果暗示，未来的运动、教育与康复类 AI 系统都可采用类似的半自动数据扩展策略，以实现持续学习与个性化适配。

3. 反馈闭环促进信任与共适应. 实验表明，闭环反馈机制不仅提升了模型决策的一致性，还显著增强了用户的信任与沉浸感。当系统能够根据用户反馈实时调整提示粒度与策略时，用户更容易将 AI 视为“合作伙伴”而非“指令系统”。这一发现为未来设计人机协作型 AI 教练提供了重要的交互设计参考。

6.3 人机共演 (Co-Agency) 的意义

EDMIT 展示了人机共演 (Co-Agency) 在交互式智能系统中的潜力。在传统人机交互中，AI 主要承担被动响应角色，而在 EDMIT 中，AI 教练与用户在持续反馈中共同塑造互动进程。这种共演机制使 AI 不仅“回应”用户的动作，更能“理解并参与”用户的决策过程。

从 HCI 理论视角看，这种共演式智能系统代表了一种新的交互范式：

- **从反应式 (Reactive) 到生成式 (Generative):** AI 不仅响应指令，而是主动生成可解释的行为计划；
- **从用户中心 (User-centered) 到共适应中心 (Co-adaptive):** 系统与用户共同调整策略以实现最优表现；
- **从任务完成到共同学习 (Co-learning):** 系统的反馈能力反过来提升用户的自我反思与学习效果。

这种人机共演模式在运动辅导场景中的成功表明，AI 不仅可以模仿人类决策，更能参与到决策生成与体验塑造之中。未来的智能辅导系统可以以此为基础，进一步探索共学习、共目

标与共信任的设计原则，推动 AI 教练向真正的“合作型智能体”方向演化。

6.4 局限与未来工作 (Limitations and Future Work)

本研究仍存在若干限制。首先，样本规模相对有限 ($n = 20$)，后续需在更大样本与更多任务类型上验证 EDMIT 的普适性。其次，目前的反馈建模主要集中于显性行为反馈，未来可结合生理或多模态数据（如姿态、表情与语音）进一步增强系统的情境感知能力。最后，如何在长期交互中平衡系统自治与用户主导，是实现真正人机共演的关键挑战。这些方向构成了我们未来研究的主要工作。

综上所述，EDMIT 不仅提供了一种可复用的智能体设计框架，也为人机交互研究揭示了新的共演视角。它展示了当 AI 从被动辅助转向主动协作时，智能系统可以在数据、算法与人类经验之间建立动态平衡，从而实现具有人类思维特征的自适应交互。

Acknowledgments

在致谢部分，应注明资金来源和其他支持，并向协助研究和论文撰写的个人及团体致谢。致谢部分应置于文档参考文献部分之前。

References

- [1] Xiaoyang Chen, Xinan Dai, Yu Du, Qian Feng, and Naixu Guo. 2025. *DeepMath-Creative: A Benchmark for Evaluating Mathematical Creativity of Large Language Models*. <http://arxiv.org/abs/2505.08744>
- [2] Micheline T.H. Chi, Stephanie A. Siler, Heisawn Jeong, Takashi Yamauchi, and Robert G. Hausmann. 2001. Learning from Human Tutoring. *Cognitive Science* 25, 4 (2001), 471–533. https://onlinelibrary.wiley.com/doi/abs/10.1207/s15516709cog2504_1
- [3] Mark Connor and Michael O'Neill. 2023. *Large Language Models in Sport Science & Medicine: Opportunities, Risks and Considerations*. <http://arxiv.org/abs/2305.03851>
- [4] DeepSeek-AI, Daya Guo, Dejian Yang, Haowei Zhang, and Junxiao Song. 2025. *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*. <http://arxiv.org/abs/2501.12948>
- [5] Ioana R. Goldbach and Felix G. Hamza-Lup. 2020. *Intelligent Tutoring Systems for Generation Z's Addiction*. <http://arxiv.org/abs/2005.05024>
- [6] Kai He, Rui Mao, Qika Lin, Yucheng Ruan, Xiang Lan, Mengling Feng, and Erik Cambria. 2025. A Survey of Large Language Models for Healthcare: From Data, Technology, and Applications to Accountability and Ethics. *Information Fusion* 118 (2025), 102963. <https://www.sciencedirect.com/science/article/pii/S1566253525000363>
- [7] Naman Jain, King Han, Alex Gu, Wen-Ding Li, and Fanjia Yan. 2024. *Live-CodeBench: Holistic and Contamination Free Evaluation of Large Language Models for Code*. <http://arxiv.org/abs/2403.07974>
- [8] Soonwoo Kwon, Sojung Kim, Minju Park, Seunghyun Lee, and Kyuseok Kim. 2024. *BIPED: Pedagogically Informed Tutoring System for ESL Education*. <http://arxiv.org/abs/2406.03486>
- [9] OpenAI, Aaron Jaech, Adam Kalai, Adam Lerer, and Adam Richardson. 2024. *OpenAI O1 System Card*. <http://arxiv.org/abs/2412.16720>
- [10] Shen Wang, Tianlong Xu, Hang Li, Chaoli Zhang, and Joleen Liang. 2024. *Large Language Models for Education: A Survey and Outlook*. <http://arxiv.org/abs/2403.18105>

A Research Methods